

S.U.R.E. Makalesi Nasıl Araştırıldı ve Yazıldı

Batuhan Çıtak · Erdem Sabri Veli

Ağustos 2026

CONTENTS

S.U.R.E. Makalesi Nasıl Araştırıldı ve Yazıldı	
pAI/MSc ile yürütölmüş bir ajan tabanlı araştırma koşusunun kaydı — insan döngü üzerinde	
1. Bu belge neden var	
2. pAI/MSc nedir	
3. Ona verdiğimiz girdi	
4. Hattın aşamaları	
4.1 Persona konseyi (3 tur)	
4.2 Düşmanca literatür taraması	
4.3 Beyin fırtınası ve hedeflerin formalizasyonu	
4.4 On bir deney	
4.5 Bağımsız doğrulama	
4.6 Yazım, hakemlik ve revizyon	
5. Deneyler gerçekte ne buldu	
6. Hat bittikten sonra kendimizin yaptığı düzeltmeler	
7. Yöntem hakkında dürüst bir değerlendirme	
8. Yeniden üretme ve yeniden kontrol	
9. Atıf	

S.U.R.E. Makalesi Nasıl Araştırıldı ve Yazıldı

PAI/MSc İLE YÜRÜTÜLMÜŞ BİR AJAN TABANLI ARAŞTIRMA KOŞUSUNUN KAYDI — İNSAN DÖNGÜ ÜZERİNDE

Proje: S.U.R.E. (Aquaculture Welfare Integration) — Kapalı Devre Su Ürünleri Yetiştiriciliği Sistemlerinde Edge-AI ve RAG Destekli Deterministik Füzyon ile Otonom Mersin Balığı Refah İzleme **Makale yazarları:** Batuhan Çıtak, Erdem Sabri Veli **Koşu aralığı:** 26–27 Ağustos 2026 **Çıktılar:** Bu depodaki [research/](#) dizini

1. Bu belge neden var

[SURE-paper.pdf](#) dosyasındaki makale elle yazılmadı. **pAI/MSc** adlı, MIT kaynaklı bir araştırma ajanı tarafından, biz insanlar döngünün üzerinde kalarak üretildi. Bu hattın ürettiği her ara çıktı, makaleyle birlikte [pipeline/](#) ve [experiments/](#) altında bu depoya işlendi.

Yalnızca ürünü değil süreci de yayımlıyoruz; üç nedenle:

- Şeffaflık.** Makine destekli bir makaleyle karşılaşan okuyucu, onun nasıl üretildiğini ve insan yargısının nereye girdiğini bilmeyi hak eder. Makale bunu teşekkür bölümünde ve sayfa filigranında zaten belirtiyor; bu belge aynı beyanın uzun hâli.
 - Denetlenebilirlik.** Hattın en değerli çıktısı metin değildi. Kendi sistemimiz hakkında inandığımız birkaç şeyi çürüten on bir yürütülmüş deneydi. Bu çelişkiler ham loglarıyla birlikte [experiments/](#) altında duruyor ve herkes yeniden kontrol edebilir.
 - Yöntem.** Hâlihazırda kurulmuş bir sistemin üzerinde bir araştırma ajanı çalıştırmak, “yapay zekâya makale yazdırmak”tan gerçekten farklı bir iş çıktı. Bu belge, rahatsız edici yerler dâhil, ne olduğunu anlatıyor.
-

2. pAI/MSc nedir

pAI/MSc, MIT teknik raporu “*pAI/MSc: ML Theory Research with Humans on the Loop*” içinde tanımlanan bir araştırma hattıdır; yazarları Mahmoud Abdelmoneum, Pierfrancesco Beneventano ve Tomaso Poggio (MIT, Technical Report v0, 2026) — https://dspace.mit.edu/handle/1721.1/165377SMARTPANTS_PRESERVED_101.SMART-PANTS_PRESERVED_102

Tasarım öncülü şu: bir araştırma ajanı tek bir uzun prompt olmamalı. Bunun yerine, farklı ajanların birbiriyle tartıştığı, literatür taramasının araştırmacının kendi özgünlük iddialarına karşı düşmanca (adversarial) yürütüldüğü, deneylerin onları koşturan ajandan bağımsız biçimde doğrulandığı ve insana yalnızca birkaç kritik noktada karar sorulduğu aşamalı bir hat. “Humans on the loop” ifadesi tam olarak bunu anlatıyor: insan her adımın içinde değil, döngünün üzerinde.

Makale bu raporu `pAIMSc 2026` olarak kaynak gösteriyor ve teşekkür bölümünde şunu belirtiyor: “We partially used pAI/MSc for this manuscript.” Derlenmiş PDF ayrıca her sayfasında düşük kontrastlı bir arka plan filigranı taşıyor: “Generated with a research agent created by Pierfrancesco Beneventano.” Bu filigran kasıtlıdır ve aracın atıf gerekliliğinin bir parçasıdır — bir render hatası değildir.

Buradaki “kısmen” tam olarak ne demek: hakkında yazılan sistemin kendisi — kod, modeller, eğitim koşulları, görüntü veri seti — bize ait ve makaleden önce vardı. Hat; literatür temellendirmesini, deney tasarımı, deneylerin mevcut kod tabanımız üzerinde yürütülmesini, bağımsız doğrulamayı ve metin yazımını yaptı. §6’daki nihai olgusal düzeltmeler ise bize aittir.

3. Ona verdiğimiz girdi

Tek girdi `pipeline/research_task.md` idi — sistemi, mimariyi, elimizdeki ampirik sayıları ve istediğimiz çerçeveyi anlatan bir sayfalık bir brief. Yanında, ajanın idealize edilmiş bir sistem yerine gerçekten var olan sistem hakkında yazması için deponun kendi `README.md`, `MODEL_RAPORU.md`, `PLAN.md` ve `TODOS.md` dosyalarını bağlam olarak verdik.

Bu brief sonra `pipeline/vision.md` dosyasına dondurulur — hattın üzerine yazmasına izin verilmeyen, salt-okunur bir “vizyon kilidi”. Sonraki her aşamadaki her persona, herhangi bir öneriyi değerlendirmeden önce orijinal brief’i okur; böylece koşu, gerçekte istediğimiz şeyden sessizce uzaklaşamaz. Bu önemliydi: hat, koşunun sonunda o brief’teki çerçeveye karşı argüman üretiyordu ve bu anlaşmazlığı görünmez değil okunabilir kılan şey tam da o kilit.

4. Hattın aşamaları

Makine tarafından okunabilir tam kayıt `pipeline/state.json`; zaman damgalı faz zaman çizelgesi `pipeline/token_summary.json`. Yaklaşık yirmi altı saatlik takvim süresi içinde kırk dört ajan çağırısı.

4.1 PERSONA KONSEYİ (3 TUR)

Üç düşmanca hakem personası — **pratik**, **titizlik (rigor)** ve **anlatı** — öneriyi bağımsız olarak eleştirdi, ardından bir sentez turu geldi; bu üçü de `ACCEPT` dönene kadar üç tur tekrarlandı. Tam metinleri `pipeline/personas/` altında.

Hasarı veren, titizlik personasıdır. Makalenin merkezî iddiasının orijinal brief’imizdekinden daha dar olmasının sebebi odur.

4.2 DÜŞMANCA LİTERATÜR TARAMASI

Tek geçiş, 31 atıf ve asıl önemli sayı: **iddialarımızın 11’i çürütüldü ya da zayıflatıldı**.

Manşet sonuç hem rahatsız ediciydi hem de doğrudu: deterministik bir kural motorunun bir LLM’in şiddet kararı üzerinde nihai yetkiyi elinde tuttuğu “özgün” çift katmanlı mimarimiz `EQUIVALENT_KNOWN` olarak sınıflandırıldı. Bu, Safety Instrumented Systems kalıbıdır (IEC 61508 / 61511), RL shielding’dir ve sektörün standart LLM-guardrail düzenlemesidir. Yerleşik bir fikre bağımsız olarak varmıştık ve onu yeni diye sunmak üzereydik.

Taramanın önerisi “makaleyi bırakın” değildi. Katkıyı **katmanlar arası tutarlılık kompozisyonu** (cross-layer consistency composition) olarak yeniden çerçevelemektir — makale şu anda tam olarak bunu savunuyor. Bkz. `pipeline/literature_review.md` ve `pipeline/novelty_flags.json`.

4.3 BEYİN FIRTINASI VE HEDEFLERİN FORMALİZASYONU

48 aday yaklaşım üretildi (`pipeline/brainstorm.md`) ve ön kayıtlı başarı ölçütleriyle birlikte **11 biçimsel araştırma hedefine** damıtıldı. Bunlara ön kayıtlı *yedek* bulgular da dâhildi: bir hipotezin güçlü hâli tutmazsa ne rapor edileceği (`pipeline/research_goals.json`). Ayrışma kapısı, işin teorik değil ampirik olduğuna karar verdi; bu yüzden teori hattı hiç koşmadı.

İnsan kontrol noktası #1. Hat burada durdu ve deneylere işlem gücü harcamadan önce hedefleri onaylamamızı istedi. Ampirik hattı onayladık.

Ön kayıt, bir sonraki bölüme dışını veren şeydir: yedek bulgular deneyler koşmadan *önce* yazıldığı için, hat hayal kırıklığı yaratan bir sonucu sonradan “zaten aradığımız buydu” diye yeniden çerçeveleyemedi.

4.4 ON BİR DENEY

`experiments/experiment_design.json` içinde tasarlandı, gerçek kod tabanımız üzerinde üç paralel grup hâlinde yürütüldü; EXP10 ve EXP11 en sonda bir finalizasyon geçişi olarak koştu-ruldu. Her birinin ham betiği, stdout logu ve sonuç dosyaları `experiments/EXP01/` ... `experi-`

ments/EXP11/ altında.

4.5 BAĞIMSIZ DOĞRULAMA

Ayrı bir doğrulayıcı ajan, özetlere güvenmek yerine her manşet metriği diskteki ham çıktı dosyalarından yeniden hesapladı — **8 PASS, 3 PARTIAL, 0 FAIL** ([experiments/verification_report.md](#)). Örneklem küçük olduğu yerlerde (n=8, n=9, n=98) doğrulayıcı bunu satır içinde söylüyor; sayıyı niteliksiz bırakmıyor.

Tamamlanma oranı **0.95**, tavsiye **COMPLETE** ([pipeline/verify_completion.json](#)).

4.6 YAZIM, HAKEMLIK VE REVIZYON

Yazıma geçmeden önce ikinci bir persona konseyi koştı, bir anlatı-ses geçişi tonu belirledi, ardından iki tam yazım döngüsü, redaksiyon ve simüle edilmiş bir hakem değerlendirmesi geldi. Hakem makaleyi **10 üzerinden 8** puanladı — sağlamlık 3, sunum 4, katkı 3, açıklık 4, özlülük 3 — **ai_voice_risk: low**, **sıfır sert engel** ve tek bir zorunlu düzeltme ([pipeline/review_verdict.json](#)), tam rapor: [pipeline/review_report.pdf](#)).

O tek zorunlu düzeltme, doğrulayıcının ne işe yaradığının iyi bir örneği: giriş bölümü eskimiş bir sayının “düzeltmeden haftalar sonra” fark edildiğini iddia ediyordu; §6.6 ve Bilinen Kısıtlar ise “43 dakikalık commit farkı” diyordu. Hakem gerçek git log’una baktı, **0e8b414** ve **9a260af** commit’lerinin aynı gün 43 dakika arayla atıldığını buldu ve girişi yalnızca tutarsız değil, olgusal olarak yanlış diye işaretledi. Düzeltildi.

Son bir hakemlik-sonrası persona konseyi iki tur boyunca üç personadan da **ACCEPT** döndü, sıfır anlatı vetosuyla. Hattın beş kapısının tamamı — fizibilite, hat ayrıştırma, ikilik, hakem kalitesi, hakemlik-sonrası personalar — geçildi.

5. Deneyler gerçekte ne buldu

Asıl okunmaya değer bölüm burası. Birkaç sonuç, brief’i yazarken inandığımız şeyle çelişiyor.

#	Soru	Bulgu
EXP01	RAG erişimi gerçek mi, yoksa 8 belgelik küçücük bir korpusun yan ürünü mü?	Gerçek. <code>e5-small</code> , rastgele referans çizgisini hit@1 +0.586 (0.793'e karşı 0.207) ve MRR +0.438 ile geçiyor. Yapılandırılmış 0.85 eşiğinin, F1-argmax olan 0.84'e karşı kesinlik-lehine olduğu doğrulandı.
EXP02	Değerlendirme koşum hattı ile çalışma zamanı yolu <i>aynı</i> kuralları mı işletiyor?	Evet — çıktı karşılaştırmasıyla değil, modül-kimliği kontrolüyle kanıtlandı. 8/8 senaryo uyumu.
EXP03	Çift katmanlı sistem gerçekte nasıl davranıyor?	Merkezî sonuç ve beklediğimiz sonuç değil. 8 senaryoda: kural motoru LLM'in düşük tahminini gerçekten 1 vakada (%12) yakaladı; 4 vakada (%50) ise modelin çıktısı ayrıştırılmadığı için güvenli tarafa düştü. Baskın güvenlik mekanizması hata düzeltme değil — bozuk çıktıda güvenli varsayılanı düşmek. Dahası: 8 gerekçe metninden 6'sı , girdide hiç bulunmayan uydurulmuş sensör değerleri içeriyordu; bunlara modelin nihai kararının kurallarla <i>uyuştuğu</i> kova da dâhil. Yalnızca çıktıya bakan bir değerlendirme bunu göremez.
EXP04	Daha büyük AQUA-7B modeli araç seçimini daha iyi mi yapıyor?	Hayır. Düşmanca bir yeniden koşumun ardından 9/9 bağımsız senaryoda sürekli aynı ilk aracı seçiyor. Korunmuş bir negatif sonuç.
EXP05	Görüntü veri setinde eğitim/doğrulama sızıntısı var mı?	Algısal karma (perceptual hash) ile 32 yakın-kopya kare çifti bulundu (14'ü komşu indeksli). <code>PARTIAL</code> işaretlendi — sayıldı ama henüz düzeltilmiş bir manşet metriğe dönüştürülmedi.
EXP06	ONNX/TorchScript dışı aktarımları doğruluk kaybediyor mu?	Hayır. Görünen kayıp, ortak son-işleme kaynaklı bir yapaylık — 98 tespitin 0'ı anlamlı biçimde farklıydı.

#	Soru	Bulgu
EXP07	Manşet recall değeri, gerçekte çalıştığımız recall mı?	Hayır. Yapılandırılmış çalışma noktası (conf=0.20) recall 0.782 veriyor; yaygın olarak alıntılanan 0.719 ise F1-argmax optimumu. İkisi de doğru; farklı sorulara cevap veriyorlar ve makale artık ikisini ayrı ayrı raporluyor. Doğrulama seti ayrıca hiç seyrek (k=1, k=2) kare içermiyor — tümüyle test edilmemiş bir rejim.
EXP08	Eşit genişlikli PSI kutulaması kesinlikle daha mı iyi?	Hayır — iddiamızın düzeltilmesi gerekti. Küçük dağılım kaymalarında <i>daha az</i> duyarlı, büyüklerinde ise belirli bir kutu boşaldığı için <i>daha patlayıcı</i> . Monotonik değil.
EXP09	<code>twin_bridge</code> sağlam mı?	Mevcut 19 testin 18'i geçiyor; tek hata bir test yardımcısındaki bug. Git'te takip edilmiyordu, commit geçmişi yoktu.
EXP10	Makalenin merkezî iddiası bu hâliyle savunulabilir mi?	Daraltılması önerildi. Yükseltme işlevi koşulsuz güvenli-varsayılane düşmedir, sofistike hata düzeltme değil; ve uydurulmuş-ama-kararı-doğru gerekçelere karşı sıfır koruma var.
EXP11	Sistemdeki sayılar makaledeki sayılarla tutarlı mı?	Canlı bir veri bütünlüğü hatası. <code>llm-service/knowledge/06-davranis-ve-refah-gostergeleri.md:58</code> hâlâ recall ≈ 0.695 diyor — aşılmış bir değer — ve bu dosya RAG vektör deposuna gerçekten besleniyor ; yani erişim katmanı eskimiş bir sayıyı servis edebilir. Toplamda altı eskimiş veya tutarsız değer kataloglandı.

Makalenin özeti artık orijinal çerçevemizi değil EXP03 ve EXP10'u yansıtıyor. Öne sürdüğü iddia bilinçli olarak dar ve yanlışlanabilir: böyle bir hat, güvenilir bir modele karşı güvenli hâle getirilebilir — *ancak doğrulayıcısı tek bir sayılabilir alandan fazlasını okumuyorsa ve her zaman muhafazakâr varsayılane düşüyorsa*. Bu, arayüz tasarımı hakkında bir iddiadır; modelin güvenilir kılındığı iddiası değil.

6. Hat bittikten sonra kendimizin yaptığı düzeltmeler

Hat tamamlandı ve tüm kapılarını geçti. Sonrasında makaleyi yeniden açtık ve onun kendi başına yapamayacağı düzeltmeleri yaptık; çünkü bunlar yalnızca bizim bildiğimiz olgulara dayanıyordu. Tamamı `pipeline/state.json` içinde `post_completion_human_revision` altında kayıtlı.

Makale geneline yayılmış olgusal bir aşırı-iddia. Taslak, S.U.R.E.’ün canlı, sahaya kurulmuş bir sistem olduğunu ima ediyordu. Değil. Şu maddeler artık Giriş’te, Deneysel Kurulum’da ve Bilinen Kısıtlar’ın ilk maddesi olarak açıkça belirtiliyor:

- **Hiçbir test gerçek fiziksel sensör veya çalışan bir RAS tesisi kullanmadı.** Böyle bir sensör donanımı mevcut değil. Tüm deneylerdeki her sensör okuması **sentetik olarak üretildi**, kaydedilmedi.
- **510 görüntülük görüntü veri seti gerçek** — fiziksel düzeneğin kamera görüntüleri, elle etiketlenmiş — ama kasıtlı olarak küçük; genişletilmesi planlanıyor.
- **TEKNOFEST’e katılmadık** — S.U.R.E.’ün kendisi için geliştirildiği yarışma — ve ön değerlendirme turunu geçemedik.
- **Asıl katkı bir fizibilite ve kaynak yönetimi gösterimidir** — bu biçimdeki çok bileşenli bir hattın uç (edge) donanımın bellek ve işlem bütçesine sığıp sığmadığını sınamak — **karar doğruluğunun saha validasyonu değil.**

”Deployed”, “production” ve “real-world” ifadelerinin her kullanımı on bir bölümün tamamında yeniden okundu. Bir *yapılandırma parametresi değerine* yapılan meşru atıflar korundu; canlı saha operasyonu ima eden her şey “implemented” veya “offline, bench-level evaluation” olarak düzeltildi.

Üç şekil render hatası. Şekil 2’de çakışan açıklamalar, Şekil 3’te y eksenini bozan ve bir eksen etiketinin üzerine çizen menzile dışı bir açıklama, Şekil 4’te eşik etiketlerinin üstünden geçen PSI eğrileri — hepsi paper/figures/make_figures.py içinde açık eksen sınırları, beyaz metin kutuları ve birbirine çok yakın noktalar için ayrı kılavuz oklarıyla düzeltildi; her şekil öncesi ve sonrasıyla render edilip gözle kontrol edilerek doğrulandı.

Düzeltilmiş makale 32 sayfa olarak, sıfır hatayla yeniden derleniyor.

7. Yöntem hakkında dürüst bir değerlendirme

Nerede açıkça işe yaradı. Düşmanca literatür taraması, bilinen bir kalıbı özgün diye yayımlamamızı engelledi. Ön kayıtlı yedek bulgular sayesinde EXP03’ün hayal kırıklığı yaratan sonucu sessizce yeniden çerçevelenmek yerine bulgu olarak raporlandı. Bağımsız doğrulama — özetleri okumak yerine ham dosyalardan yeniden hesap yapan ikinci bir ajan — kendi içinde tutarlı bir taslağın yayına kadar taşıyacağı “haftalar” / “43 dakika” hatasını yakaladı. EXP11 ise makale yazmakla hiç ilgisi olmayan, canlı kod tabanındaki gerçek ve düzeltilmemiş bir hatayı buldu.

İnsanın vazgeçilmez olduğu yer. §6’daki düzeltmelerin tamamı bizden geldi. Hattın; sensörlerimizin sentetik olduğunu, donanımın hiç var olmadığını ya da yarışmaya hiç katılmadığımızı bilmesinin bir yolu yoktu, çünkü depoda bunu söyleyen hiçbir şey yoktu — ve o boşluğun etrafına kendinden emin, iyi kaynaklandırılmış, kendi içinde tutarlı bir makale yazdı. Bir araştırma ajanı, ona verdiğiniz öncülleri sadakatle uzatır. Öncülleri denetlemek, devredilebilecek bir adım değildir.

Sınırları. Örneklem, en çok ağırlık taşıyan yerlerde küçük: merkezî davranışsal sonuç $n=8$. Üç deney `PARTIAL` ve `EXP05`’in sızıntı bulgusu sayıldı ama henüz düzeltilmiş bir manşet görüntü metriğine yansıtılmadı — açık bir görev ve makalede üstü örtülmek yerine böyle ifade ediliyor.

8. Yeniden üretme ve yeniden kontrol

```
# Makaleyi kaynaktan yeniden derle (bir TeX dağıtımı gerekir)
cd research/paper
pdflatex final_paper.tex && bibtex final_paper && pdflatex final_paper.tex &&
pdflatex final_paper.tex

# Beş şekli yeniden üret
cd research/paper/figures && python make_figures.py
```

[experiments/](#) altındaki her deney dizini, koşturulan betiği, stdout logunu ve sonuç dosyalarını içerir. Doğrulayıcının her manşet sayıyı bağımsız olarak yeniden hesaplaması

[experiments/verification_report.md](#) içindedir.

Boyut nedeniyle tek bir dosya dışarıda bırakıldı: `EXP05/near_duplicate_pairs_full.json` (2.4 MB, tam algısal-karma çift dökümü). Toplaştırılmış değerleri `EXP05/exp05_summary.json` içinde ve onu üreten denetim betiği `EXP05/exp05_leakage_audit.py` depoya işlenmiş durumda.

9. Atıf

S.U.R.E. sisteminin kendisi — backend, görüntü servisi, LLM servisi, MLOps ve dijital ikiz köprüsü — yazarların kendi çalışmasıdır ve bu makaleden öncedir.

Makale, MIT’de Mahmoud Abdelmoneum, Pierfrancesco Beneventano ve Tomaso Poggio tarafından geliştirilen **pAI/MSc** araştırma ajanıyla üretilmiştir ve makalenin kaynakçasında ve teşekkür bölümünde bu şekilde belirtilmiştir. Derlenmiş PDF’in her sayfasındaki arka plan fil-

ıgranı, o aracın atıf gerekliliđinin bir parçasıdır.

Abdelmoneum, M., Beneventano, P., & Poggio, T. (2026). *pAI/MSc: ML Theory Research with Humans on the Loop*. MIT Technical Report v0.

https://dspace.mit.edu/handle/1721.1/165377SMARTPANTS_PRESERVED_503SMART-PANTS_PRESERVED_504